

# Fundamentos matemáticos de la IA

La Inteligencia Artificial (IA) y el Machine Learning se fundamentan en diversas ramas de las matemáticas. Estas herramientas permiten modelar datos, optimizar funciones y comprender patrones complejos. Los principales pilares matemáticos que se utilizan en IA son:

- **Probabilidad y Estadística:** Para modelar la incertidumbre, analizar datos y hacer inferencias.
- **Cálculo:** Fundamental en la optimización de modelos (por ejemplo, en el ajuste de parámetros mediante gradientes).
- **Álgebra Lineal:** Esencial para representar datos en forma de vectores y matrices, y para operaciones que se utilizan en algoritmos de aprendizaje.

A continuación, desarrollaremos cada uno de estos temas en detalle.

## 1. Probabilidad

La probabilidad es la rama de las matemáticas que estudia la incertidumbre y se utiliza para modelar eventos aleatorios.

### 1.1 Conceptos Básicos

#### Espacio Muestral y Eventos

- **Espacio muestral (S):** Es el conjunto de todos los posibles resultados de un experimento aleatorio.  
Ejemplo: Para el lanzamiento de un dado,  $S = \{1, 2, 3, 4, 5, 6\}$ .
- **Evento (A):** Es un subconjunto del espacio muestral.  
Ejemplo: Sacar un número par:  $A = \{2, 4, 6\}$ .

#### Definición de Probabilidad

La probabilidad de un evento  $A$  se define como:

$$P(A) = \frac{\text{Número de resultados favorables a } A}{\text{Número total de resultados en } S}$$

#### Ejemplo 1.1:

Para el dado:

- Número total de resultados: 6.
- Número de resultados favorables para obtener un número par: 3 (2, 4 y 6).

$$P(\text{par}) = \frac{3}{6} = 0.5$$

## 1.2 Variables Aleatorias y Funciones de Distribución

### Variable Aleatoria

Una variable aleatoria es una función que asigna un número real a cada resultado del espacio muestral.

#### Ejemplo:

En el lanzamiento de un dado, definimos la variable aleatoria  $X$  que toma el valor del número obtenido.

### Función de Probabilidad (para variables discretas)

La función de probabilidad  $p(x)$  asigna la probabilidad de que  $X$  tome un valor  $x$ :

$$p(x) = P(X = x)$$

Para el dado,  $p(x) = \frac{1}{6}$  para  $x = 1, 2, \dots, 6$ .

### Función de Distribución Acumulada (CDF)

La función de distribución acumulada  $F(x)$  se define como:

$$F(x) = P(X \leq x) = \sum_{t \leq x} p(t)$$

## 1.3 Esperanza, Varianza y Desviación Estándar

### Esperanza o Valor Esperado

La esperanza  $E[X]$  de una variable aleatoria  $X$  es el promedio ponderado de todos los valores posibles, con sus probabilidades:

$$E[X] = \sum_i x_i p(x_i)$$

#### Ejemplo 1.2:

Para el dado, el valor esperado es:

$$E[X] = \frac{1 + 2 + 3 + 4 + 5 + 6}{6} = \frac{21}{6} = 3.5$$

### Varianza

La varianza  $\text{Var}(X)$  mide la dispersión de la variable respecto a su media:

$$\text{Var}(X) = E[(X - E[X])^2] = \sum_i (x_i - E[X])^2 p(x_i)$$

### Ejemplo 1.3:

Para el dado, usando  $E[X] = 3.5$ :

$$\begin{aligned}\text{Var}(X) &= \frac{(1 - 3.5)^2 + (2 - 3.5)^2 + (3 - 3.5)^2 + (4 - 3.5)^2 + (5 - 3.5)^2 + (6 - 3.5)^2}{6} \\ &= \frac{(2.5)^2 + (1.5)^2 + (0.5)^2 + (0.5)^2 + (1.5)^2 + (2.5)^2}{6} = \frac{6.25 + 2.25 + 0.25 + 0.25 + 2.25 + 6.25}{6} = \frac{17.5}{6} \approx 2.92\end{aligned}$$

### Desviación Estándar

La desviación estándar  $\sigma$  es la raíz cuadrada de la varianza:

$$\sigma = \sqrt{\text{Var}(X)}$$

$$\sigma \approx \sqrt{2.92} \approx 1.71$$

## 1.4 Distribuciones de Probabilidad Comunes

### Distribución Binomial

Se utiliza para modelar el número de éxitos en  $n$  ensayos independientes, cada uno con probabilidad  $p$  de éxito.

La función de probabilidad es:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

donde:

- $\binom{n}{k} = \frac{n!}{k!(n-k)!}$  es el coeficiente binomial,
- $n$  es el número total de ensayos,
- $k$  es el número de éxitos.

### Ejemplo 1.4:

Supongamos 10 lanzamientos de una moneda justa ( $p = 0.5$ ), la probabilidad de obtener 6 caras:

$$P(X = 6) = \binom{10}{6} (0.5)^6 (0.5)^4 = \binom{10}{6} (0.5)^{10}$$

$$\binom{10}{6} = \frac{10!}{6!4!} = 210, \quad \text{entonces } P(X = 6) = 210 \times (0.5)^{10} = 210 \times \frac{1}{1024} \approx 0.205$$

## 2. Estadística

La estadística se ocupa de recolectar, analizar e interpretar datos. Es crucial en la IA para la toma de decisiones basadas en datos.

### 2.1 Medidas Descriptivas

#### Media

La media (o promedio) de un conjunto de datos  $x_1, x_2, \dots, x_n$  es:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

##### Ejemplo 2.1:

Para los datos 4, 8, 6, 5, 3:

$$\bar{x} = \frac{4 + 8 + 6 + 5 + 3}{5} = \frac{26}{5} = 5.2$$

#### Mediana

La mediana es el valor central de un conjunto de datos ordenado.

##### Ejemplo:

Para  $\{3, 4, 5, 8, 9\}$ , la mediana es 5.

#### Moda

La moda es el valor que ocurre con mayor frecuencia.

##### Ejemplo:

En  $\{2, 3, 3, 5, 7\}$ , la moda es 3.

### 2.2 Inferencia Estadística

#### Intervalos de Confianza

Un intervalo de confianza es un rango de valores que se utiliza para estimar un parámetro poblacional, con un cierto nivel de confianza (por ejemplo, 95%).

La fórmula para un intervalo de confianza para la media (cuando la varianza es conocida o el tamaño de la muestra es grande) es:

$$\bar{x} \pm Z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

donde:

- $\bar{x}$  es la media muestral,
- $Z_{\alpha/2}$  es el valor crítico de la distribución normal (por ejemplo, para 95% es 1.96),
- $\sigma$  es la desviación estándar poblacional,
- $n$  es el tamaño de la muestra.

## Ejemplo 2.2:

Supongamos que se mide la altura de 100 estudiantes y se obtiene una media de 170 cm con  $\sigma = 10$  cm. El intervalo de confianza al 95% es:

$$170 \pm 1.96 \cdot \frac{10}{\sqrt{100}} = 170 \pm 1.96 \cdot 1 = 170 \pm 1.96$$

$$\text{Intervalo: } [168.04, 171.96]$$

## Regresión Lineal Simple

La regresión lineal modela la relación entre una variable independiente  $x$  y una dependiente  $y$  usando una línea recta:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

donde:

- $\beta_0$  es la intersección (ordenada al origen),
- $\beta_1$  es la pendiente,
- $\varepsilon$  es el término de error.

Para estimar  $\beta_0$  y  $\beta_1$ , se usan las siguientes fórmulas (mínimos cuadrados):

$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

## Ejemplo 2.3:

Considera los siguientes datos:

- $x : 1, 2, 3, 4$
- $y : 2, 3, 5, 4$

Calculamos:

- $\bar{x} = \frac{1+2+3+4}{4} = 2.5$
- $\bar{y} = \frac{2+3+5+4}{4} = 3.5$

Calcular  $\beta_1$ :

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = (1 - 2.5)(2 - 3.5) + (2 - 2.5)(3 - 3.5) + (3 - 2.5)(5 - 3.5) + (4 - 2.5)(4 - 3.5)$$

$$= (-1.5)(-1.5) + (-0.5)(-0.5) + (0.5)(1.5) + (1.5)(0.5) = 2.25 + 0.25 + 0.75 + 0.75 = 4$$

$$\sum (x_i - \bar{x})^2 = (-1.5)^2 + (-0.5)^2 + (0.5)^2 + (1.5)^2 = 2.25 + 0.25 + 0.25 + 2.25 = 5$$

$$\beta_1 = \frac{4}{5} = 0.8$$

$$\beta_0 = 3.5 - 0.8 \times 2.5 = 3.5 - 2 = 1.5$$

La ecuación de la recta es:

$$y = 1.5 + 0.8x$$

## 3. Cálculo

El cálculo es fundamental para la optimización en IA, ya que se utiliza para encontrar mínimos y máximos de funciones de pérdida y ajustar parámetros de modelos.

### 3.1 Derivadas y Gradiente

#### Derivada de una Función

La derivada de una función  $f(x)$  es el límite que define la tasa de cambio instantánea:

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

##### Ejemplo 3.1:

Para  $f(x) = x^2$ :

$$f'(x) = \lim_{h \rightarrow 0} \frac{(x+h)^2 - x^2}{h} = \lim_{h \rightarrow 0} \frac{2xh + h^2}{h} = \lim_{h \rightarrow 0} (2x + h) = 2x$$

#### Gradiente de una Función de Múltiples Variables

El gradiente es un vector de derivadas parciales y apunta en la dirección de mayor aumento de la función:

$$\nabla f(x_1, x_2, \dots, x_n) = \left( \frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$$

### Ejemplo 3.2:

Para  $f(x, y) = x^2 + y^2$ :

$$\frac{\partial f}{\partial x} = 2x, \quad \frac{\partial f}{\partial y} = 2y$$

Entonces,

$$\nabla f(x, y) = (2x, 2y)$$

## Aplicación en Optimización: Descenso del Gradiente

El **descenso del gradiente** es un método para minimizar funciones (por ejemplo, la función de pérdida en un modelo de IA).

La regla de actualización para cada parámetro  $\theta$  es:

$$\theta := \theta - \alpha \nabla f(\theta)$$

donde:

- $\alpha$  es la tasa de aprendizaje (learning rate),
- $\nabla f(\theta)$  es el gradiente en  $\theta$ .

### Ejemplo 3.3:

Supongamos que queremos minimizar  $f(x) = (x - 3)^2$ .

- La derivada es  $f'(x) = 2(x - 3)$ .
- Con un  $\alpha = 0.1$  y  $x_0 = 0$ , la actualización es:

$$x_1 = x_0 - 0.1 \times 2(0 - 3) = 0 - 0.1 \times (-6) = 0 + 0.6 = 0.6$$

- Repetir el proceso:

$$x_2 = 0.6 - 0.1 \times 2(0.6 - 3) = 0.6 - 0.1 \times (-4.8) = 0.6 + 0.48 = 1.08$$

El proceso se repite hasta que  $x$  se aproxime a 3, que es el mínimo de la función.

## 4. Álgebra Lineal

El álgebra lineal es esencial para el procesamiento de datos en IA, ya que los datos se representan en forma de vectores y matrices.

### 4.1 Vectores y Operaciones

Un vector es una lista ordenada de números. Por ejemplo, un vector en  $\mathbb{R}^3$  se puede escribir como:

$$\mathbf{v} = \begin{pmatrix} v_1 \\ v_2 \\ v_3 \end{pmatrix}$$

## Suma y Producto por Escalar

- Suma de vectores:

$$\mathbf{u} + \mathbf{v} = \begin{pmatrix} u_1 + v_1 \\ u_2 + v_2 \\ u_3 + v_3 \end{pmatrix}$$

- Producto por un escalar  $c$ :

$$c\mathbf{v} = \begin{pmatrix} c \cdot v_1 \\ c \cdot v_2 \\ c \cdot v_3 \end{pmatrix}$$

### Ejemplo 4.1:

Sean  $\mathbf{u} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$  y  $\mathbf{v} = \begin{pmatrix} 4 \\ 5 \\ 6 \end{pmatrix}$ .

- Suma:

$$\mathbf{u} + \mathbf{v} = \begin{pmatrix} 1 + 4 \\ 2 + 5 \\ 3 + 6 \end{pmatrix} = \begin{pmatrix} 5 \\ 7 \\ 9 \end{pmatrix}$$

- Producto por escalar (por 2):

$$2\mathbf{u} = \begin{pmatrix} 2 \cdot 1 \\ 2 \cdot 2 \\ 2 \cdot 3 \end{pmatrix} = \begin{pmatrix} 2 \\ 4 \\ 6 \end{pmatrix}$$

## 4.2 Matrices y Multiplicación

Una matriz es una colección de números organizados en filas y columnas. Por ejemplo, una matriz  $A$  de dimensión  $m \times n$  es:

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}$$

### Multiplicación de Matrices

Si  $A$  es de dimensión  $m \times n$  y  $B$  es  $n \times p$ , el producto  $C = A \cdot B$  es una matriz  $m \times p$  definida como:

$$c_{ij} = \sum_{k=1}^n a_{ik} b_{kj}$$

### Ejemplo 4.2:

Sean



$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}, \quad B = \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix}$$

El producto  $C = A \cdot B$  es:

$$c_{11} = 1 \cdot 5 + 2 \cdot 7 = 5 + 14 = 19$$

$$c_{12} = 1 \cdot 6 + 2 \cdot 8 = 6 + 16 = 22$$

$$c_{21} = 3 \cdot 5 + 4 \cdot 7 = 15 + 28 = 43$$

$$c_{22} = 3 \cdot 6 + 4 \cdot 8 = 18 + 32 = 50$$

Entonces,

$$C = \begin{pmatrix} 19 & 22 \\ 43 & 50 \end{pmatrix}$$

## 4.3 Eigenvalores y Eigenvectores

En muchos algoritmos de IA (por ejemplo, en reducción de dimensionalidad o análisis de componentes principales), se utilizan los eigenvalores y eigenvectores.

### Definición

Para una matriz cuadrada  $A$ , un vector no nulo  $\mathbf{v}$  es un eigenvector si existe un escalar  $\lambda$  (eigenvalor) tal que:

$$A\mathbf{v} = \lambda\mathbf{v}$$

Para encontrar  $\lambda$ , se resuelve el **polinomio característico**:

$$\det(A - \lambda I) = 0$$

donde  $I$  es la matriz identidad.

### Ejemplo 4.3:

Sea

$$A = \begin{pmatrix} 4 & 2 \\ 1 & 3 \end{pmatrix}$$

El polinomio característico es:

$$\det \left( \begin{pmatrix} 4-\lambda & 2 \\ 1 & 3-\lambda \end{pmatrix} \right) = (4-\lambda)(3-\lambda) - 2 \cdot 1 = \lambda^2 - 7\lambda + 10 = 0$$

Resolviendo:

$$\lambda^2 - 7\lambda + 10 = 0 \quad \Rightarrow \quad (\lambda - 5)(\lambda - 2) = 0$$

Por lo tanto, los eigenvalores son  $\lambda = 5$  y  $\lambda = 2$ .

Para  $\lambda = 5$ :

$$(A - 5I)\mathbf{v} = \begin{pmatrix} -1 & 2 \\ 1 & -2 \end{pmatrix} \mathbf{v} = \mathbf{0}$$

Una solución es  $\mathbf{v} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$  (después de normalizar si se requiere).

## Recursos adicionales

1. **"Mathematics for Machine Learning"** por Marc Peter Deisenroth, A. Aldo Faisal, y Cheng Soon Ong.
  - Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). *Mathematics for machine learning*. Cambridge University Press.
  - Este libro es una excelente introducción a los conceptos matemáticos necesarios para el aprendizaje automático. Cubre álgebra lineal, cálculo, probabilidad, estadística y optimización, con un enfoque en cómo se aplican estos temas en la IA. Es muy completo y tiene muchos ejemplos. Es, en mi opinión, la mejor opción de las tres que te presento.
2. **"The Elements of Statistical Learning: Data Mining, Inference, and Prediction"** por Trevor Hastie, Robert Tibshirani, y Jerome Friedman.
  - Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer.
  - Aunque se centra más en el aprendizaje estadístico, este libro es una referencia fundamental. Explica conceptos clave como la regresión, la clasificación, los métodos de regularización, y los modelos lineales generalizados. Es un clásico, pero puede ser un poco más avanzado. El libro se puede descargar gratuitamente desde la página web de los autores.
3. **"Linear Algebra and Its Applications"** por Gilbert Strang.
  - Strang, G. (2016). *Linear algebra and its applications* (5th ed.). Wellesley-Cambridge Press.
  - Gilbert Strang es reconocido por su habilidad para explicar el álgebra lineal de manera clara y accesible. Este libro es un recurso excelente para dominar los conceptos de vectores, matrices, transformaciones lineales, valores propios y más. Incluye muchas aplicaciones prácticas.

### Recursos en Línea Gratuitos:

1. **Khan Academy:**
  - <https://www.khanacademy.org/>
  - Khan Academy ofrece cursos gratuitos en línea sobre álgebra lineal, cálculo, probabilidad y estadística. Los videos son muy didácticos y hay muchos ejercicios para practicar. Es ideal para repasar conceptos o aprender desde cero. Los temas individuales son:

- Álgebra lineal: <https://www.khanacademy.org/math/linear-algebra>
- Cálculo: <https://www.khanacademy.org/math/calculus-1> (y cursos de cálculo más avanzados)
- Probabilidad y estadística: <https://www.khanacademy.org/math/statistics-probability>

## 2. MIT OpenCourseWare:

- <https://ocw.mit.edu/>
- El MIT ofrece acceso gratuito a los materiales de muchos de sus cursos, incluyendo cursos de matemáticas relevantes para la IA. Puedes encontrar clases magistrales en video, notas de clase y problemas resueltos. Algunos cursos relevantes:
  - 18.06 Linear Algebra (Álgebra Lineal): <https://ocw.mit.edu/courses/18-06-linear-algebra-spring-2010/> (impartido por Gilbert Strang)
  - 6.041 Probabilistic Systems Analysis and Applied Probability (Análisis de Sistemas Probabilísticos y Probabilidad Aplicada): <https://ocw.mit.edu/courses/6-041-probabilistic-systems-analysis-and-applied-probability-fall-2010/>
  - 18.065 Matrix Methods in Data Analysis, Signal Processing, and Machine Learning (Métodos Matriciales en Análisis de Datos, Procesamiento de Señales y Aprendizaje Automático): <https://ocw.mit.edu/courses/18-065-matrix-methods-in-data-analysis-signal-processing-and-machine-learning-spring-2018/>

## 3. 3Blue1Brown

- <https://www.youtube.com/c/3blue1brown>
- Es un canal de youtube que realiza animaciones de muy alta calidad sobre temas complejos de matemáticas, donde explica de manera sumamente visual, álgebra lineal y cálculo.